Tugas UTS Riset Informatika

Perbandingan Algoritma Apriori dan FIN untuk Analisis Pola Pembelian dan Rekomendasi Paket Bundling Produk pada Data Transaksi Swalayan

Dosen Pengampu:

Prof. Dr. Basuki Rahmat, S.Si, MT

Disusun Oleh:

Nugraini Dewi Puspitasari (23081010260)

PROGRAM STUDI INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" JAWA TIMUR

2026

DAFTAR ISI

DAFTAR ISI ..... **ii**

DAFTAR GAMBAR ..... **iv**

DAFTAR TABEL ..... **v**

BAB I PEDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 2

1.3 Batasan Masalah 3

1.4 Tujuan Penelitian 3

1.5 Manfaat Penelitian 4

BAB II TINJAUAN PUSTAKA **5**

2.1 Penelitian Terdahulu 5

2.2 Data Mining 7

2.3 *Market Basket Analysis* 7

2.4 *Association Rule Mining* 8

2.5 Algoritma Apriori 8

2.6 Algoritma FIN 9

2.7 Metrik Evaluasi 10

2.8 Product Bundling 12

BAB III METODOLOGI PENELITIAN **14**

3.1 Metode Penelitian 14

3.2 Desain Sistem 14

3.2.1 Pengumpulan dan Deskripsi Dataset 15

3.2.2 Preprocessing Data Transaksi 17

3.2.3 Implementasi Algoritma Apriori 19

3.2.4 Perhitungan Manual Apriori 20

3.2.5 Implementasi Algoritma FIN 22
3.2.6 Perhitungan Manual FIN..... 23
3.2.7 Pembentukan Aturan Asosiasi..... 24
3.2.8 Perancangan Rekomendasi Paket Bundling..... 25
3.2.9 Perancangan Pengujian dan Evaluasi..... 26
DAFTAR PUSTAKA 29

DAFTAR GAMBAR

Gambar 3. 1 Flowchart Alur Sistem Penelitian di sini.....15
Gambar 3. 2 Flowchart Implementasi Algoritma Apriori.....19
Gambar 3. 3 Flowchart Implementasi Algoritma FIN.....22

DAFTAR TABEL

Tabel 2. 1 Ringkasan perbandingan penelitian terdahulu 6
Tabel 3. 1 Contoh Data Detail Transaksi Penjualan 16
Tabel 3. 2 Contoh Data Keranjang Belanja 16
Tabel 3. 3 Contoh Transaksi untuk Perhitungan Manual Apriori 21
Tabel 3. 4 Perhitungan minimum support count 26

BAB I
PEDAHULUAN

1.1 Latar Belakang

Aktivitas penjualan pada usaha ritel menghasilkan data transaksi yang dapat digunakan untuk mempelajari pola pembelian produk. Informasi dalam transaksi tidak hanya menunjukkan produk yang terjual, tetapi juga memungkinkan analisis terhadap produk-produk yang muncul secara bersamaan dalam satu keranjang belanja. Salah satu pendekatan yang dapat digunakan untuk menganalisis hubungan tersebut adalah *Market Basket Analysis*, yang diterapkan dalam penelitian transaksi supermarket oleh [1] .

Dalam penerapannya, *Market Basket Analysis* dapat menggunakan *Association Rule Mining* untuk menemukan hubungan antarproduk berdasarkan pola kemunculannya dalam transaksi. Saptadi, Chyan, dan Leda [2] menerapkan pendekatan aturan asosiasi pada data pembelian supermarket untuk mengidentifikasi produk yang memiliki keterkaitan dalam transaksi. Informasi tersebut dapat digunakan sebagai bahan pertimbangan dalam pengelolaan produk dan penataan barang, meskipun keputusan bisnis tetap perlu mempertimbangkan kondisi operasional swalayan.

Algoritma Apriori merupakan salah satu metode yang dapat digunakan untuk menemukan *frequent itemsets*, yaitu kombinasi item yang memenuhi nilai minimum *support* yang ditentukan. Penelitian Rahman dan Riana [3] membandingkan Apriori dengan FP-Growth pada data penjualan ritel serta membahas pemanfaatan hasil analisis untuk rekomendasi bundling. Perbandingan algoritma pada data transaksi juga dilakukan oleh Wahyuningsih et al. [1] , yang menguji Apriori, FP-Growth, dan ECLAT pada data transaksi Supermarket X tahun 2021. Penelitian tersebut melaporkan bahwa ECLAT memiliki waktu eksekusi paling singkat dalam skenario pengujian mereka, sehingga hasil perbandingan algoritma perlu dipahami sesuai data dan kondisi eksperimen yang digunakan.

Selain Apriori, penelitian ini menggunakan algoritma FIN (*Frequent Itemset Mining*) sebagai algoritma pembanding. Kallay dan Mihoc [4] membahas sejumlah algoritma pencarian pola frekuen, termasuk Apriori dan FIN, dengan memperhatikan aspek seperti waktu eksekusi, penggunaan memori, dan skalabilitas. Khajuria et al. [5] juga mengevaluasi FIN bersama beberapa algoritma lain menggunakan empat dataset nyata. Hasil penelitian mereka memperlihatkan bahwa kinerja algoritma dapat berbeda menurut dataset yang digunakan.

Temuan tersebut menjadi alasan untuk melakukan pengujian pada data penelitian sendiri, alih-alih menganggap hasil dari dataset lain akan berlaku sama pada seluruh data transaksi.

Hasil analisis pola pembelian dapat dimanfaatkan untuk mengidentifikasi kombinasi produk yang berpotensi dijadikan calon paket *bundling*. Rizqi [6] membahas penggunaan *Association Rule-Market Basket Analysis* untuk menentukan strategi *product bundling* pada usaha ritel, dengan memperhatikan parameter *support* dan *confidence*. Sementara itu, Septianingsih dan Santoso [7] menerapkan Apriori untuk rekomendasi *cross-selling* produk ritel serta mengevaluasi aturan menggunakan *support*, *confidence*, dan *lift*. Kedua penelitian tersebut relevan untuk menjelaskan bagaimana aturan asosiasi dapat dimanfaatkan sebagai dasar penyusunan rekomendasi produk, tanpa berarti bahwa efektivitas promosi telah terbukti sebelum dilakukan pengujian bisnis.

Penelitian ini menggunakan data transaksi dari satu cabang swalayan selama periode 1 Januari hingga 31 Desember 2025, yang terdiri atas 35.218 transaksi dan 5.517 produk unik. Algoritma Apriori dan FIN akan diuji pada data serta nilai minimum *support* yang sama, yaitu 0,05%, 0,10%, dan 0,20%. Perbandingan dilakukan berdasarkan waktu eksekusi algoritma, jumlah *frequent itemsets*, dan kesesuaian hasil itemset yang ditemukan oleh kedua algoritma. Aturan asosiasi selanjutnya dianalisis menggunakan metrik *support*, *confidence*, dan *lift* untuk mengidentifikasi kombinasi produk yang berpotensi menjadi calon paket bundling.

Dengan rancangan tersebut, penelitian ini berfokus pada perbandingan Apriori dan FIN dalam konteks data transaksi swalayan tahun 2025 serta pemanfaatan pola asosiasi yang dihasilkan untuk menyusun calon paket bundling produk. Fokus tersebut berbeda dari penelitian yang membandingkan Apriori dengan FP-Growth atau ECLAT [1], [3], maupun penelitian yang mengevaluasi FIN bersama algoritma pencarian pola frekuen lainnya pada beberapa dataset [4], [5]. Oleh karena itu, posisi penelitian ini perlu diletakkan pada pengujian kedua algoritma dalam kondisi yang sama pada dataset yang digunakan, bukan pada klaim bahwa perbandingan Apriori dan FIN belum pernah dilakukan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana algoritma Apriori dan FIN menemukan *frequent itemset* pada data transaksi swalayan?
2. Bagaimana perbandingan waktu eksekusi dan hasil *frequent itemset* kedua algoritma?

3. Bagaimana hasil aturan asosiasi dari kedua algoritma berdasarkan nilai *support*, *confidence*, dan *lift* dapat digunakan untuk mengidentifikasi kombinasi produk yang berpotensi menjadi calon paket bundling?

1.3 Batasan Masalah

Agar penelitian lebih terarah dan pembahasan sesuai dengan tujuan yang telah ditetapkan, batasan masalah dalam penelitian ini adalah sebagai berikut.

1. Data yang digunakan merupakan data transaksi penjualan dari satu cabang swalayan selama periode 1 Januari hingga 31 Desember 2025.
2. Data penelitian terdiri atas 35.218 transaksi dengan 5.517 produk unik. Data tersebut digunakan untuk menganalisis pola pembelian produk berdasarkan keterkaitan produk yang muncul dalam transaksi yang sama.
3. Algoritma yang dibandingkan dalam penelitian ini adalah Apriori dan Frequent Itemset Mining (FIN). Perbandingan dilakukan untuk mengetahui perbedaan kinerja kedua algoritma dalam menemukan frequent itemsets berdasarkan nilai minimum support yang ditentukan.
4. Pengujian dilakukan menggunakan tiga nilai minimum support, yaitu 0,05%, 0,10%, dan 0,20%. Nilai tersebut digunakan untuk mengamati hasil penemuan frequent itemsets dan waktu eksekusi masing-masing algoritma.
5. Evaluasi kinerja algoritma mencakup waktu eksekusi, jumlah frequent itemsets, dan kesesuaian frequent itemsets yang dihasilkan. Pengukuran waktu eksekusi dibatasi pada proses kerja algoritma, tidak termasuk waktu pemuatan data dan prapemrosesan.
6. Hasil *frequent itemsets* dari masing-masing algoritma digunakan untuk membentuk *association rules* dengan menerapkan nilai minimum confidence sebesar 10% (0,10). Aturan asosiasi yang dihasilkan dianalisis berdasarkan nilai support, confidence, dan lift untuk mengidentifikasi pola keterkaitan produk yang berpotensi dijadikan rekomendasi paket bundling.
7. Rekomendasi paket bundling dibatasi pada usulan berdasarkan pola pembelian dalam data transaksi. Penelitian ini tidak menguji penerapan promosi bundling secara langsung maupun mengukur dampaknya terhadap peningkatan penjualan.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan penelitian ini adalah sebagai berikut.

1. Menerapkan algoritma Apriori dan FIN pada dataset transaksi yang sama.

2. Membandingkan jumlah, kesesuaian *frequent itemset*, dan waktu eksekusi.
3. Menganalisis *association rules* yang dihasilkan dari kedua algoritma berdasarkan nilai *support*, *confidence*, dan *lift* untuk mengidentifikasi pola keterkaitan produk yang berpotensi dijadikan rekomendasi paket *bundling*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1. Manfaat Akademis

   Penelitian ini diharapkan dapat menambah pemahaman mengenai perbandingan algoritma Apriori dan FIN dalam menemukan *frequent itemsets* pada data transaksi ritel. Hasil penelitian juga dapat menjadi referensi untuk penelitian selanjutnya yang membahas perbandingan algoritma penambangan pola frekuensi serta penerapan *association rule mining* dalam analisis pola pembelian produk.

2. Manfaat Praktis

   Bagi pengelola swalayan, hasil penelitian ini diharapkan dapat memberikan informasi mengenai pola keterkaitan pembelian produk berdasarkan data transaksi. Pola tersebut dapat digunakan sebagai bahan pertimbangan dalam menyusun rekomendasi paket *bundling* produk, dengan tetap mempertimbangkan kebijakan dan kondisi operasional swalayan.

BAB II
TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian terdahulu digunakan untuk mengetahui perkembangan algoritma *frequent itemset mining*, analisis pola pembelian, dan pemanfaatan aturan asosiasi dalam menentukan rekomendasi produk. Penelitian yang relevan ditinjau berdasarkan metode yang digunakan, objek penelitian, hasil atau kontribusi, serta hubungannya dengan penelitian ini. Perbandingan tersebut digunakan untuk menjelaskan posisi penelitian mengenai perbandingan algoritma Apriori dan FIN pada data transaksi swalayan.

Kallay dan Mihoc [4] membahas perbandingan berbagai algoritma *frequent pattern mining*, termasuk Apriori dan FIN. Penelitian tersebut mengkaji kinerja algoritma dengan mempertimbangkan aspek waktu eksekusi, penggunaan memori, dan skalabilitas. Penelitian ini relevan sebagai landasan perbandingan algoritma, tetapi penelitian yang dilakukan berfokus pada pengujian Apriori dan FIN menggunakan satu dataset transaksi swalayan dengan beberapa nilai *minimum support* yang telah ditentukan.

Penelitian Wahyuningsih et al. [1] membandingkan algoritma Apriori, FP-Growth, dan ECLAT menggunakan data transaksi Supermarket X tahun 2021. Penelitian tersebut menunjukkan bahwa perbedaan algoritma dapat menghasilkan perbedaan kinerja pada kondisi pengujian yang digunakan. Penelitian ini memiliki kesamaan dalam penggunaan data transaksi supermarket dan perbandingan algoritma, tetapi menggunakan FIN sebagai algoritma pembanding Apriori. Sementara itu, Rahman dan Riana [3] membandingkan Apriori dengan FP-Growth untuk analisis pola pembelian pada data penjualan retail. Penelitian tersebut menjadi referensi terkait penggunaan algoritma asosiasi dalam analisis transaksi retail, sedangkan penelitian ini secara khusus membandingkan Apriori dan FIN serta memanfaatkan hasilnya untuk menyusun kandidat paket bundling.

Penelitian mengenai pemanfaatan pola pembelian untuk penyusunan paket produk juga telah dilakukan oleh Rizqi, yang membahas penggunaan *Association Rule–Market Basket Analysis* untuk menentukan strategi *product bundling* pada usaha retail [6]. Fang et al. mengembangkan pendekatan penyusunan paket produk pada supermarket daring dengan memanfaatkan *frequent itemset mining* dan optimasi [8]. Kedua penelitian tersebut relevan dalam menjelaskan pemanfaatan pola pembelian sebagai dasar penyusunan paket produk. Meskipun demikian, penelitian ini tidak berfokus pada optimasi paket atau pengujian

dampak promosi, melainkan pada perbandingan hasil pencarian pola oleh Apriori dan FIN serta identifikasi kandidat bundling dari transaksi historis.

Penelitian Buana dan Vikaliana menerapkan *Market Basket Analysis* menggunakan Apriori untuk mendukung strategi *product bundling* pada toko daring [9]. Selain itu, Hibnastiar et al. menerapkan Apriori untuk menghasilkan rekomendasi paket produk pada toko peralatan listrik [10]. Kedua penelitian tersebut menunjukkan penerapan algoritma Apriori untuk menghasilkan rekomendasi paket pada konteks usaha yang berbeda. Penelitian ini memperluas konteks perbandingan dengan melibatkan FIN dan mengevaluasi kesesuaian *frequent itemsets* yang dihasilkan oleh kedua algoritma pada dataset transaksi swalayan yang sama.

Tabel 2. 1 Ringkasan perbandingan penelitian terdahulu

No	Peneliti dan Tahun	Metode atau Fokus	Kontribusi Penelitian	Perbedaan dengan Penelitian Ini
1	Kallay dan Mihoc (2025)	Perbandingan berbagai algoritma *frequent pattern mining*, termasuk Apriori dan FIN.	Mengkaji kinerja algoritma, antara lain waktu eksekusi, penggunaan memori, dan skalabilitas.	Penelitian ini berfokus pada perbandingan Apriori dan FIN pada data transaksi satu swalayan dengan tiga nilai minimum support
2	Wahyuningsih, Suharsono, dan Iriawan (2023)	Apriori, FP-Growth, dan ECLAT pada transaksi Supermarket X tahun 2021.	Membandingkan kinerja algoritma dalam analisis pola pembelian supermarket.	Algoritma pembanding dalam penelitian ini adalah Apriori dan FIN.
3	Rahman dan Riana (2025)	Perbandingan Apriori dan FP-Growth pada data penjualan retail.	Mengkaji penerapan algoritma untuk analisis pola pembelian dan aturan asosiasi retail.	Penelitian ini menggunakan FIN sebagai pembanding Apriori serta memeriksa kesesuaian *frequent itemsets*.
4	Rizqi (2022)	*Association Rule–Market Basket Analysis* untuk strategi bundling retail.	Membahas pemanfaatan aturan asosiasi untuk mendukung strategi paket produk.	Penelitian ini membandingkan dua algoritma pencarian pola sebelum memanfaatkan hasilnya untuk kandidat bundling.
5	Fang et al. (2022)	*Frequent itemset* mining dan optimasi untuk bundling supermarket daring.	Memanfaatkan pola pembelian dan optimasi dalam penyusunan paket produk.	Penelitian ini tidak berfokus pada optimasi paket, tetapi pada perbandingan algoritma dan identifikasi kandidat bundling dari data historis.
6	Buana dan Vikaliana (2024)	Apriori untuk strategi bundling pada toko daring.	Menerapkan analisis pola pembelian untuk mendukung rekomendasi paket produk.	Penelitian ini membandingkan Apriori dan FIN pada transaksi swalayan.

7	Hibnastiar, Setiawan, dan Susanto (2025)	Apriori untuk rekomendasi paket produk pada toko peralatan listrik.	Menghasilkan rekomendasi paket dan mempertimbangkan kategori produk untuk meningkatkan relevansi rekomendasi.	Penelitian ini membandingkan hasil kedua algoritma dan kinerja komputasinya pada dataset yang sama.

Berdasarkan penelitian terdahulu, algoritma *frequent itemset mining* telah digunakan untuk menganalisis pola pembelian, sedangkan aturan asosiasi dimanfaatkan untuk mendukung rekomendasi paket bundling produk. Penelitian ini berfokus pada perbandingan kinerja algoritma Apriori dan FIN menggunakan dataset transaksi swalayan dengan kondisi pengujian yang sama, serta pemanfaatan hasil analisis pola asosiasi untuk mengidentifikasi kandidat paket bundling berdasarkan transaksi historis

2.2 Data Mining

Data mining merupakan proses untuk menemukan pola atau informasi yang bermanfaat dari sekumpulan data melalui teknik analisis tertentu. Salah satu pendekatannya adalah *Frequent Pattern Mining* (FPM), yaitu proses menemukan pola yang memenuhi batas frekuensi tertentu dalam suatu dataset. Kallay dan Mihoc membahas penggunaan sejumlah algoritma FPM, termasuk Apriori dan FIN, serta membandingkan kinerjanya berdasarkan beberapa aspek, seperti waktu eksekusi dan penggunaan memori [4].

Dalam penelitian ini, data mining digunakan untuk menganalisis data transaksi swalayan periode Januari–Desember 2025. Analisis dilakukan dengan membandingkan algoritma Apriori dan FIN dalam menemukan *frequent itemsets*. Pola yang diperoleh selanjutnya digunakan untuk membentuk aturan asosiasi dan mengidentifikasi kandidat paket bundling produk.

2.3 *Market Basket Analysis*

Market Basket Analysis (MBA) merupakan teknik analisis data yang digunakan untuk mengidentifikasi pola pembelian produk berdasarkan catatan transaksi. Analisis ini bertujuan menemukan produk-produk yang sering muncul secara bersamaan dalam satu transaksi sehingga hubungan antarproduk dapat dipelajari. Dalam penerapannya pada bidang ritel, hasil analisis dapat dimanfaatkan sebagai bahan pertimbangan untuk menyusun strategi pemasaran dan penataan produk [11], [12] .

Penerapan MBA umumnya melibatkan pencarian *frequent itemsets* dan pembentukan *association rules*. *Frequent itemsets* merupakan kumpulan satu atau lebih produk yang kemunculannya memenuhi nilai minimum *support* yang ditetapkan. Selanjutnya, aturan

asosiasi digunakan untuk menggambarkan hubungan antara kombinasi produk, misalnya dalam bentuk $X \rightarrow Y$, yang menunjukkan hubungan antara produk atau kelompok produk (X) dan (Y). Penelitian pada data transaksi supermarket oleh Saptadi et al. menunjukkan bahwa analisis aturan asosiasi dapat digunakan untuk mengidentifikasi hubungan pembelian produk dan menjadi bahan pertimbangan dalam pengelolaan produk supermarket [12].

Dalam penelitian ini, MBA digunakan untuk menganalisis data transaksi swalayan selama periode Januari hingga Desember 2025. Algoritma Apriori dan FIN diterapkan untuk menemukan *frequent itemsets*, kemudian hasilnya digunakan dalam pembentukan aturan asosiasi. Aturan yang diperoleh dianalisis berdasarkan nilai *support*, *confidence*, dan *lift* untuk mengidentifikasi kombinasi produk yang berpotensi dijadikan kandidat paket bundling.

2.4 *Association Rule Mining*

Association Rule Mining (ARM) merupakan teknik dalam data mining yang digunakan untuk menemukan hubungan atau asosiasi antaritem dalam suatu kumpulan data. Teknik ini menghasilkan aturan berbentuk $X \rightarrow Y$, dengan (X) sebagai *antecedent* (bagian yang mendahului) dan (Y) sebagai *consequent* (bagian yang mengikuti). Dalam konteks transaksi penjualan, aturan tersebut menggambarkan kecenderungan kemunculan suatu produk atau kelompok produk bersama produk lainnya dalam data transaksi [13].

Proses ARM secara umum terdiri atas dua tahap. Tahap pertama adalah menemukan *frequent itemsets*, yaitu kombinasi item yang memenuhi batas minimum *support*. Tahap kedua adalah membentuk aturan asosiasi dari kombinasi tersebut dan menyeleksi aturan berdasarkan batas minimum *confidence*. Bao et al. menjelaskan bahwa *support* dan *confidence* merupakan ukuran yang umum digunakan dalam evaluasi aturan asosiasi, tetapi keduanya memiliki keterbatasan sehingga ukuran lain, seperti *lift*, juga dapat digunakan untuk membantu menilai hubungan antaritem [13].

Dalam penelitian ini, aturan asosiasi dibentuk dari hasil *frequent itemsets* yang dihasilkan oleh algoritma Apriori dan FIN. Pembentukan aturan menggunakan nilai minimum *confidence* sebesar 10% secara konsisten pada kedua algoritma. Aturan yang terbentuk kemudian dianalisis menggunakan *support*, *confidence*, dan *lift* untuk menilai frekuensi kemunculan kombinasi produk, kecenderungan hubungan antarproduk, dan kekuatan asosiasinya sebagai dasar pemilihan kandidat paket bundling.

2.5 Algoritma Apriori

Algoritma Apriori merupakan salah satu algoritma *frequent itemset mining* yang digunakan untuk menemukan kombinasi item yang sering muncul bersama dalam kumpulan transaksi. Dalam analisis transaksi penjualan, hasil pencarian tersebut dapat digunakan untuk mengidentifikasi pola pembelian dan menjadi dasar pembentukan aturan asosiasi. Penerapan Apriori pada transaksi penjualan telah digunakan untuk menemukan kombinasi produk yang dapat mendukung penyusunan strategi penjualan [14], [15].

Apriori bekerja dengan pendekatan *level-wise*, yaitu mencari kombinasi item secara bertahap berdasarkan jumlah item dalam setiap kombinasi. Prosesnya dimulai dengan menghitung frekuensi setiap item untuk memperoleh *frequent 1-itemset*, kemudian membentuk kandidat kombinasi yang lebih besar dari itemset yang memenuhi syarat. Setiap kandidat diperiksa berdasarkan nilai *support* untuk menentukan apakah kandidat tersebut termasuk *frequent itemset* [15], [4].

Prinsip utama Apriori adalah bahwa jika suatu *itemset* tidak memenuhi nilai minimum *support*, kombinasi yang lebih besar yang mengandung itemset tersebut juga tidak dapat memenuhi nilai minimum *support*. Prinsip ini digunakan untuk memangkas kandidat yang tidak perlu diproses pada tahap berikutnya. Meskipun demikian, Apriori tetap melakukan pembentukan kandidat dan pemeriksaan frekuensi secara berulang, sehingga jumlah kandidat dan banyaknya pemindaian transaksi dapat memengaruhi waktu eksekusi algoritma [16], [4] .

Tahapan Apriori berakhir ketika tidak ada lagi kandidat yang memenuhi minimum *support*. Kumpulan *frequent itemset* yang diperoleh selanjutnya dapat digunakan untuk membentuk *association rules* dengan menghitung ukuran seperti *confidence* dan *lift*. Setiawan [14], misalnya, menerapkan Apriori pada transaksi penjualan sneakers untuk menemukan kombinasi item dan menghasilkan aturan asosiasi yang dapat dimanfaatkan dalam strategi penjualan. Dengan demikian, Apriori dapat digunakan sebagai salah satu pendekatan untuk menganalisis pola pembelian produk dalam data transaksi ritel [14], [15].

2.6 Algoritma FIN

Algoritma FIN (*Frequent Itemset Mining*) merupakan algoritma untuk menemukan kombinasi item yang memenuhi minimum *support* pada data transaksi. Algoritma ini menggunakan struktur data *Nodeset* untuk mendukung proses pencarian *frequent itemset*. Kallay dan Mihoc [4] menjelaskan bahwa FIN menggunakan *pre-order coded tree* (POC-tree), *Nodeset*, dan *set-enumeration tree* dalam mekanisme pencariannya. Pendekatan

tersebut membedakan FIN dari Apriori yang menggunakan pembentukan kandidat secara bertingkat [4].

Proses FIN dimulai dengan membangun POC-tree dan mengidentifikasi *frequent 1-itemset*. Selanjutnya, algoritma mencari *frequent 2-itemset* beserta representasi *Nodeset*-nya, kemudian melanjutkan pencarian kombinasi dengan jumlah item yang lebih besar melalui *set-enumeration tree*. Dalam proses tersebut, FIN menggunakan strategi *promotion* sebagai mekanisme *pruning* berdasarkan sifat kesetaraan superset untuk mengurangi ruang pencarian yang perlu ditelusuri [4].

Struktur *Nodeset* dirancang untuk merepresentasikan informasi simpul menggunakan kode penelusuran *pre-order* atau *post-order*, sehingga tidak memerlukan kedua jenis kode secara bersamaan. Penelitian awal tentang FIN melaporkan evaluasi waktu eksekusi dan penggunaan memori dengan membandingkannya terhadap PrePost dan FP-Growth. Namun, hasil tersebut berasal dari dataset dan skenario eksperimen penelitian tersebut, sehingga tidak dapat langsung dianggap sebagai bukti bahwa FIN akan selalu lebih unggul pada setiap dataset [4].

Berdasarkan perbedaan mekanisme tersebut, Apriori dan FIN dapat dibandingkan untuk mengetahui bagaimana masing-masing algoritma menemukan *frequent itemset* pada dataset yang sama. Perbandingan perlu mempertimbangkan hasil pola yang ditemukan serta waktu eksekusi pada kondisi pengujian yang setara. Kallay dan Mihoc juga membahas perbandingan berbagai algoritma pencarian pola dan menunjukkan pentingnya mempertimbangkan karakteristik dataset serta sumber daya komputasi ketika mengevaluasi kinerja algoritma [4].

2.7 Metrik Evaluasi

Metrik evaluasi digunakan untuk menilai hasil dan kinerja algoritma yang diterapkan dalam penelitian. Pada penelitian ini, evaluasi mencakup perbandingan waktu eksekusi dan jumlah *frequent itemset* yang dihasilkan oleh Apriori dan FIN. Penggunaan waktu eksekusi dan jumlah pola sebagai ukuran perbandingan sejalan dengan penelitian mengenai algoritma *frequent itemset mining* yang mengevaluasi waktu pemrosesan pada berbagai karakteristik dataset [13].

Waktu eksekusi (*execution time*) merupakan durasi yang diperlukan algoritma untuk menyelesaikan proses pencarian *frequent itemset*. Waktu yang lebih singkat menunjukkan bahwa proses pencarian dapat diselesaikan lebih cepat pada kondisi pengujian tersebut. Sementara itu, jumlah *frequent itemset* menunjukkan banyaknya kombinasi item yang

memenuhi nilai minimum *support*. Kedua ukuran ini perlu diamati bersama karena waktu pemrosesan dan jumlah pola yang ditemukan dapat dipengaruhi oleh karakteristik data serta parameter yang digunakan [13].

Selain itu, kesesuaian hasil *frequent itemset* digunakan untuk memeriksa apakah Apriori dan FIN menemukan kombinasi item yang sama. Pemeriksaan dilakukan dengan membandingkan isi kombinasi yang dihasilkan kedua algoritma pada dataset dan nilai minimum *support* yang sama. Aspek ini merupakan bagian dari rancangan evaluasi penelitian ini untuk memeriksa konsistensi hasil, bukan ukuran kualitas aturan asosiasi yang berdiri sendiri.

Evaluasi aturan asosiasi dilakukan menggunakan tiga ukuran, yaitu *support*, *confidence*, dan *lift.* Bao et al. [13] membahas ketiga ukuran tersebut beserta keterbatasan pendekatan evaluasi aturan asosiasi konvensional. Vives-Mestres et al. [17] juga menjelaskan penggunaan ukuran tersebut untuk menilai frekuensi kemunculan aturan, peluang kemunculan konsekuen berdasarkan anteseden, serta hubungan antara item dalam aturan asosiasi.

Support menunjukkan proporsi transaksi yang memuat kombinasi item dalam suatu aturan. Untuk aturan $A \rightarrow B$, nilai *support* dihitung menggunakan rumus berikut:

$$Support(A \rightarrow B) = \frac{count(A \cup B)}{N}$$

Confidence menunjukkan proporsi transaksi yang memuat A dan juga memuat B, di antara seluruh transaksi yang memuat B. Rumusnya adalah:

$$Confidence(A \rightarrow B) = \frac{Support(A \cup B)}{Support\ (A)}$$

Sementara itu, *lift* digunakan untuk menilai hubungan antara A dan B dengan mempertimbangkan frekuensi kemunculan B secara keseluruhan. Nilai *lift* lebih dari 1 menunjukkan hubungan positif, nilai mendekati 1 menunjukkan bahwa kedua item relatif independen, sedangkan nilai kurang dari 1 menunjukkan hubungan negatif [13], [17].

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support\ (B)}$$

Dalam penelitian ini, *support*, *confidence*, dan *lift* digunakan untuk mengevaluasi aturan asosiasi yang diperoleh dari hasil Apriori dan FIN. Aturan yang memenuhi kriteria penelitian selanjutnya dapat dipertimbangkan sebagai kandidat *product bundling*.

Meskipun demikian, aturan dengan nilai metrik yang memenuhi kriteria tidak secara otomatis membuktikan bahwa paket bundling tersebut akan meningkatkan penjualan, karena penelitian ini mengevaluasi pola transaksi historis dan tidak menguji dampak promosi secara langsung.

2.8 Product Bundling

Product bundling merupakan strategi pemasaran yang menggabungkan dua atau lebih produk ke dalam satu paket penawaran. Dalam konteks retail, penentuan produk yang sesuai untuk digabungkan dapat dilakukan dengan menganalisis pola pembelian konsumen berdasarkan data transaksi. Melalui pendekatan tersebut, produk yang sering muncul secara bersamaan dalam transaksi dapat diidentifikasi sebagai kandidat paket produk. Dengan demikian, pemanfaatan data transaksi dapat membantu proses penyusunan rekomendasi bundling berdasarkan pola pembelian yang ditemukan, bukan hanya berdasarkan perkiraan.

Penelitian Fang et al. membahas pengembangan paket produk pada supermarket daring menggunakan pendekatan *frequent itemset mining* dan optimasi. Penelitian tersebut terlebih dahulu mengidentifikasi kombinasi produk yang sering muncul bersama berdasarkan analisis aturan asosiasi. Selanjutnya, kontribusi penjualan dari kombinasi produk dipertimbangkan untuk memilih kandidat paket yang sesuai dengan karakteristik wilayah konsumen. Penelitian ini menunjukkan bahwa hasil penambangan pola pembelian dapat digunakan sebagai dasar dalam menyusun kandidat *product bundling*, sementara proses pemilihan paket dapat mempertimbangkan kriteria tambahan sesuai kebutuhan bisnis [8].

Pada penelitian nasional, Buana dan Vikaliana menerapkan *Market Basket Analysis* menggunakan algoritma Apriori untuk mendukung strategi *product bundling* pada toko daring Athaku. Penelitian tersebut menggunakan 4.229 transaksi pada periode 1 Januari hingga 30 September 2022. Dengan menerapkan nilai *minimum support* sebesar 0,15 dan *minimum confidence* sebesar 0,5, penelitian tersebut menghasilkan tiga aturan asosiasi yang selanjutnya divalidasi melalui kuesioner kepada 30 konsumen. Hasil penelitian menunjukkan bahwa aturan asosiasi yang diperoleh dapat dijadikan dasar untuk mempertimbangkan paket produk pada toko tersebut [9].

Hibnastiar et.al juga menerapkan algoritma Apriori untuk menghasilkan rekomendasi paket produk pada Toko Surya Elektrik Turen. Penelitian tersebut menemukan bahwa penggunaan pola asosiasi saja dapat menghasilkan rekomendasi produk yang berulang. Untuk mengatasi permasalahan tersebut, peneliti menambahkan parameter kategori produk

agar rekomendasi yang dihasilkan menjadi lebih relevan. Hasil pengujian memperlihatkan bahwa perubahan nilai *minimum support* dan *minimum confidence*, serta penerapan pembatasan kategori, memengaruhi jumlah dan karakteristik rekomendasi paket yang dihasilkan [10]. Penelitian ini menunjukkan bahwa hasil analisis pola pembelian perlu dipertimbangkan lebih lanjut sebelum digunakan sebagai rekomendasi paket produk.

Berdasarkan penelitian-penelitian tersebut, *product bundling* dapat diposisikan sebagai salah satu pemanfaatan hasil *frequent itemset mining* dan *association rule mining*. Dalam penelitian ini, kombinasi produk yang ditemukan oleh algoritma Apriori dan FIN akan digunakan untuk mengidentifikasi kandidat paket bundling berdasarkan data transaksi swalayan selama periode Januari sampai Desember 2025. Hasil kedua algoritma dibandingkan untuk mengetahui kesesuaian *frequent itemset* yang ditemukan serta perbedaan kinerja komputasinya. Aturan asosiasi yang dibentuk dari hasil masing-masing algoritma selanjutnya dapat digunakan untuk menggambarkan hubungan pembelian antarproduk sebagai bahan pertimbangan dalam menyusun kandidat paket bundling. Kandidat tersebut merupakan rekomendasi berdasarkan pola transaksi historis, bukan bukti bahwa penerapan bundling telah meningkatkan penjualan.

BAB III
METODOLOGI PENELITIAN

3.1 Metode Penelitian

Penelitian ini menggunakan pendekatan eksperimen untuk membandingkan algoritma Apriori dan FIN dalam menemukan frequent itemset pada data transaksi swalayan. Kedua algoritma diterapkan pada dataset yang sama dengan menggunakan tiga variasi nilai minimum support, yaitu 0,05%, 0,10%, dan 0,20%. Penggunaan data dan parameter yang sama bertujuan agar hasil dari kedua algoritma dapat dibandingkan secara konsisten berdasarkan jumlah *frequent itemset*, kesesuaian kombinasi *itemset*, jumlah transaksi pendukung (*support count*), serta waktu eksekusi algoritma.

Data yang digunakan merupakan data transaksi penjualan dari satu cabang swalayan selama periode Januari sampai Desember 2025. Dataset tersebut mencakup 35.218 transaksi dan 5.517 kode produk unik. Data transaksi dipersiapkan melalui tahapan *preprocessing* dan pembentukan keranjang transaksi (*transaction basket*) agar dapat digunakan oleh kedua algoritma. Selanjutnya, algoritma Apriori dan FIN dijalankan secara terpisah untuk menemukan pola pembelian produk berdasarkan variasi minimum *support* yang telah ditentukan.

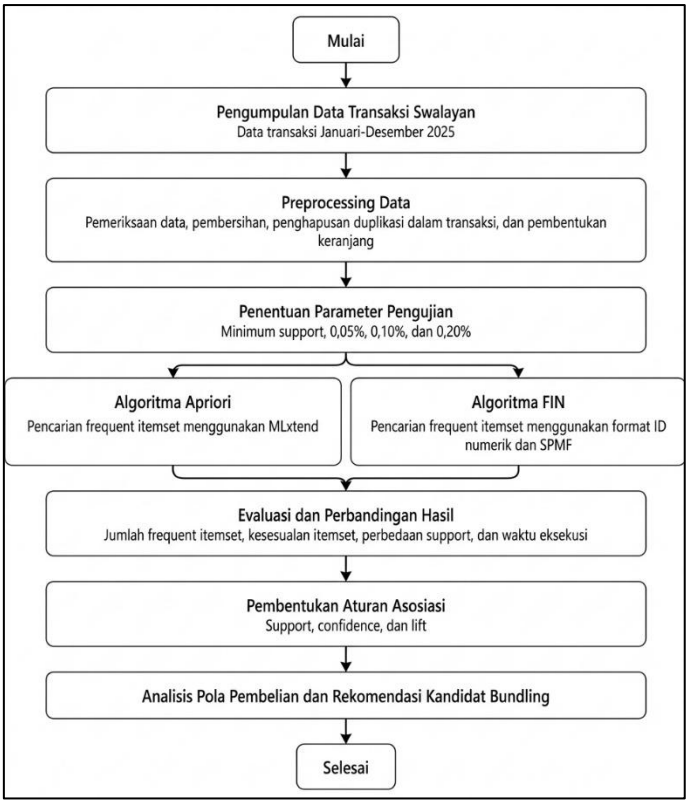
Hasil *frequent itemset* dari kedua algoritma kemudian dibandingkan untuk mengetahui kesesuaian kombinasi produk dan jumlah transaksi pendukung yang dihasilkan. Selain itu, waktu eksekusi digunakan untuk menganalisis aspek kinerja komputasi masing-masing algoritma. Hasil *frequent itemset* selanjutnya dimanfaatkan dalam pembentukan aturan asosiasi menggunakan parameter *support*, *confidence*, dan *lift*. Aturan asosiasi yang diperoleh dianalisis untuk mengidentifikasi kombinasi produk yang berpotensi menjadi kandidat paket bundling pada swalayan.

Secara umum, penelitian ini terdiri atas tahapan pengumpulan data, *preprocessing* data, penerapan algoritma Apriori dan FIN, evaluasi dan perbandingan hasil, pembentukan aturan asosiasi, serta analisis rekomendasi kandidat paket bundling. Setiap tahapan dilakukan secara berurutan untuk menghasilkan analisis pola pembelian berdasarkan data transaksi aktual swalayan.

3.2 Desain Sistem

Desain sistem pada penelitian ini disusun untuk menggambarkan rancangan proses perbandingan algoritma Apriori dan FIN dalam menemukan pola pembelian produk pada data

transaksi swalayan. Rancangan ini menjadi acuan dalam pelaksanaan penelitian, mulai dari persiapan data hingga analisis hasil pencarian pola pembelian untuk menentukan kandidat paket bundling produk. Alur pelaksanaan penelitian ditunjukkan pada Gambar 3.1.



Gambar 3. 1 Flowchart Alur Sistem Penelitian di sini

Berdasarkan Gambar 3.1, algoritma Apriori dan FIN diterapkan pada data transaksi yang telah melalui tahap *preprocessing* dengan menggunakan variasi minimum *support* yang sama. Hasil dari kedua algoritma kemudian dibandingkan untuk mengetahui kesesuaian *frequent itemset* yang dihasilkan. Hasil pencarian pola selanjutnya dimanfaatkan dalam analisis aturan asosiasi untuk mengidentifikasi kombinasi produk yang berpotensi menjadi kandidat paket bundling.

3.2.1 Pengumpulan dan Deskripsi Dataset

Data yang digunakan dalam penelitian ini merupakan data transaksi penjualan dari satu cabang swalayan selama periode Januari sampai dengan Desember 2025. Data awal diperoleh dalam format DBF, kemudian diolah menjadi format yang sesuai dengan kebutuhan penelitian. Dataset hasil pengolahan mencakup 35.218 transaksi dan 5.517 kode produk unik. Data tersebut digunakan untuk menganalisis pola pembelian berdasarkan kemunculan produk secara bersamaan dalam suatu transaksi.

Data detail transaksi memiliki atribut tanggal, nomor bukti, kode pengguna, kode produk, dan nama produk. Setiap baris merepresentasikan satu produk yang tercatat dalam suatu transaksi. Satu transaksi dapat memuat satu atau beberapa produk dengan nomor bukti yang sama. Struktur data tersebut memungkinkan identifikasi produk-produk yang dibeli secara bersamaan berdasarkan transaksi yang tercatat.

Tabel 3. 1 Contoh Data Detail Transaksi Penjualan

Tanggal	Nomor Bukti	Kode User	Kode Produk	Nama Produk
20250101	010910002	09	8992761164546	NUTRIBOOST STRAWBERY 300ML
20250102	021020050	10	8996001600399	LE MINERAL 1500ML
20250103	030910001	09	8992858665000	PROMAG OBAT MAGG 5S
20250103	030910001	09	8993883070500	INTUNAL F
20250103	030910001	09	8997021870151	FRESHCARE HOT
20250103	030910001	09	8998667100206	PARAMEX
20250103	030910001	09	8999908285003	BODREX EXTRA 4'S

Berdasarkan Tabel 3.1, nomor bukti 010910003 muncul pada beberapa baris dengan kode dan nama produk yang berbeda. Hal tersebut menunjukkan bahwa data detail menyimpan setiap produk secara terpisah meskipun produk-produk tersebut berasal dari transaksi yang sama. Oleh karena itu, data detail dapat diolah lebih lanjut menjadi bentuk keranjang transaksi untuk mendukung analisis pola pembelian.

Selain data detail, penelitian ini menggunakan representasi keranjang belanja (*transaction basket*) yang mengelompokkan produk berdasarkan tanggal dan nomor bukti transaksi. Dataset ini memiliki atribut tanggal, nomor bukti, jumlah produk, daftar kode produk, dan daftar nama produk. Setiap baris pada dataset keranjang belanja merepresentasikan satu transaksi beserta daftar produk yang terdapat di dalamnya.

Tabel 3. 2 Contoh Data Keranjang Belanja

Tanggal	Nomor Bukti	Jumlah Produk	Daftar Kode Produk	Daftar Nama Produk
20250101	010910002	1	8992761164546	NUTRIBOOST STRAWBERY 300ML
20250101	010910011	4	8934868015024|8991188943369|8991188943536|8993141122514	GARAM CERDIK 250GR | REXONA DEO LOTION FREE SPIRIT 9G | SASA 5000 | SASA SANTAN 65ML
20250102	021020050	1	8996001600399	LE MINERAL 1500ML
20250103	030910001	5	8992858665000|8993883070500|8997021870151|8998667100206|8999908285003	BODREX EXTRA 4'S | FRESHCARE HOT | INTUNAL F | PARAMEX | PROMAG OBAT MAGG 5S

Tabel 3.2 menunjukkan bahwa daftar produk dari satu transaksi disimpan dalam satu baris. Kolom jumlah produk menunjukkan banyaknya kode produk berbeda dalam keranjang, sedangkan daftar kode produk memuat identitas produk yang tercatat dalam transaksi. Daftar nama produk juga disimpan untuk membantu identifikasi dan interpretasi hasil analisis.

Dataset keranjang belanja digunakan sebagai dasar dalam penerapan algoritma Apriori dan sebagai sumber pembentukan data masukan algoritma FIN. Meskipun menggunakan representasi yang berbeda, kedua algoritma diterapkan pada data transaksi yang berasal dari sumber dan periode pengamatan yang sama. Dengan demikian, hasil pencarian *frequent itemset* dari kedua algoritma dapat dibandingkan menggunakan variasi minimum support yang telah ditentukan.

3.2.2 Preprocessing Data Transaksi

Tahap *preprocessing* dilakukan untuk mempersiapkan data transaksi agar sesuai dengan kebutuhan analisis pola pembelian menggunakan algoritma Apriori dan FIN. Data awal dalam format DBF diolah melalui pemeriksaan, pembersihan, dan pengelompokan data transaksi. Tahap ini menghasilkan representasi data yang lebih terstruktur sehingga dapat digunakan dalam proses pencarian *frequent itemset*.

Proses pemeriksaan data dilakukan dengan melewati data yang memiliki kode produk atau nomor bukti kosong. Selain itu, kode produk yang tidak ditemukan dalam data master barang atau tidak memiliki nama produk tidak disertakan dalam hasil pengolahan. Pemeriksaan

tersebut bertujuan mengurangi penggunaan data yang tidak memenuhi persyaratan dasar identifikasi produk. Meskipun demikian, pemeriksaan ini tidak menjamin bahwa seluruh kemungkinan kesalahan pada data sumber telah terdeteksi.

Selanjutnya, penanganan duplikasi dilakukan dengan menghilangkan kemunculan kode produk yang sama dalam satu transaksi. Proses ini menggunakan struktur data set sehingga setiap kode produk hanya direpresentasikan satu kali dalam keranjang yang sama. Penghapusan duplikasi tersebut hanya dilakukan pada tingkat transaksi, sehingga produk yang sama tetap dapat muncul pada transaksi lain. Transaksi yang hanya memuat satu produk tetap dipertahankan karena masih merupakan transaksi yang valid dalam data penjualan.

Setelah proses pemeriksaan dan penanganan duplikasi, data dikelompokkan berdasarkan kombinasi tanggal dan nomor bukti transaksi. Setiap kelompok membentuk satu keranjang transaksi (*transaction basket*) yang berisi daftar kode produk dan daftar nama produk. Sebagai contoh, pada data detail transaksi dengan nomor bukti 010910003 tanggal 1 Januari 2025, terdapat enam produk berbeda. Setelah dikelompokkan, produk-produk tersebut direpresentasikan dalam satu baris keranjang belanja dengan jumlah produk sebanyak enam.

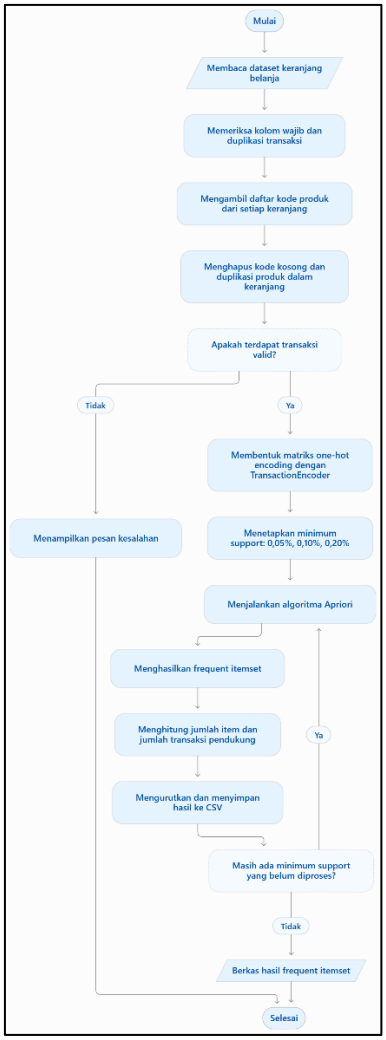
Hasil preprocessing disimpan dalam dua bentuk representasi, yaitu data detail produk per transaksi dan data keranjang belanja. Data detail mempertahankan informasi produk yang tercatat pada setiap transaksi, sedangkan data keranjang digunakan sebagai dasar pembentukan masukan algoritma. Pengelompokan ini memungkinkan proses analisis dilakukan berdasarkan keberadaan produk dalam transaksi yang sama, bukan berdasarkan setiap baris produk secara terpisah.

Pada tahap berikutnya, data keranjang disesuaikan dengan format masukan masing-masing algoritma. Algoritma Apriori menggunakan daftar kode produk pada setiap keranjang yang kemudian diubah menjadi representasi *one-hot encoding* menggunakan TransactionEncoder dari pustaka MLxtend. Sementara itu, algoritma FIN menggunakan kode produk yang telah dipetakan menjadi ID numerik dan disimpan dalam format teks sesuai kebutuhan implementasinya. Kedua format masukan tersebut berasal dari hasil pengolahan data transaksi yang sama.

Dengan demikian, tahap preprocessing mencakup pemeriksaan data, penanganan duplikasi produk dalam transaksi, pengelompokan berdasarkan tanggal dan nomor bukti, serta penyesuaian format masukan algoritma. Data hasil preprocessing selanjutnya digunakan dalam pengujian Apriori dan FIN menggunakan tiga variasi minimum support, yaitu 0,05%, 0,10%, dan 0,20%

3.2.3 Implementasi Algoritma Apriori

Implementasi algoritma Apriori pada penelitian ini dilakukan menggunakan bahasa pemrograman Python dengan memanfaatkan pustaka MLxtend. Algoritma Apriori digunakan untuk menemukan *frequent itemset*, yaitu kombinasi produk yang muncul dalam transaksi dengan frekuensi yang memenuhi nilai *minimum support* yang telah ditentukan. Proses implementasi menggunakan data keranjang belanja hasil *preprocessing*, sehingga setiap transaksi direpresentasikan sebagai kumpulan produk yang dibeli secara bersamaan.



Gambar 3. 2 Flowchart Implementasi Algoritma Apriori

Alur implementasi algoritma Apriori dapat dilihat pada Gambar 3.2. Flowchart tersebut menggambarkan tahapan proses yang dimulai dari pembacaan dataset keranjang belanja, pemeriksaan struktur data, pengambilan daftar kode produk, hingga pembentukan representasi *one-hot encoding*. Selanjutnya, algoritma Apriori dijalankan menggunakan tiga variasi

minimum support, untuk menemukan kombinasi produk yang memenuhi kriteria frekuensi kemunculan.

Proses implementasi diawali dengan membaca dataset dan memeriksa keberadaan kolom yang diperlukan serta duplikasi transaksi berdasarkan tanggal dan nomor bukti. Program kemudian mengambil daftar kode produk dari setiap keranjang, mengabaikan daftar yang kosong, dan menghilangkan kode produk yang berulang dalam keranjang yang sama. Apabila tidak terdapat transaksi valid yang dapat diproses, program akan menampilkan pesan kesalahan dan menghentikan proses.

Apabila data valid tersedia, daftar transaksi diubah menjadi representasi *one-hot encoding* menggunakan `TransactionEncoder` dari pustaka MLxtend. Dalam representasi ini, setiap baris menunjukkan satu transaksi dan setiap kolom menunjukkan satu kode produk. Nilai pada matriks menunjukkan apakah suatu produk terdapat dalam transaksi tersebut. Representasi ini selanjutnya digunakan sebagai masukan bagi fungsi `apriori()`.

Proses pencarian *frequent itemset* dilakukan secara berulang untuk setiap nilai *minimum support* yang telah ditetapkan. Hasil pencarian dilengkapi dengan jumlah produk dalam setiap kombinasi dan perkiraan jumlah transaksi pendukung yang dihitung berdasarkan nilai *support* dan jumlah transaksi yang diproses. Hasil tersebut kemudian diurutkan dan disimpan dalam berkas CSV sesuai dengan nilai *minimum support* yang digunakan.

Selain menghasilkan *frequent itemset*, program juga mengukur waktu eksekusi fungsi `apriori()` menggunakan `time.perf_counter()`. Pengukuran ini hanya mencakup waktu pelaksanaan fungsi pencarian pola, tidak termasuk pembacaan data, transformasi *one-hot encoding*, maupun penyimpanan hasil. Oleh karena itu, perbandingan waktu dengan algoritma FIN perlu menggunakan batas pengukuran proses yang sebanding agar hasilnya dapat diinterpretasikan secara tepat.

Hasil implementasi Apriori selanjutnya digunakan dalam evaluasi dan perbandingan *frequent itemset* dengan hasil algoritma FIN. Selain itu, hasil pencarian Apriori menjadi dasar pembentukan aturan asosiasi yang dianalisis menggunakan *support*, *confidence*, dan *lift* untuk mengidentifikasi kombinasi produk yang berpotensi menjadi kandidat paket *bundling*.

3.2.4 Perhitungan Manual Apriori

Perhitungan manual dilakukan untuk memberikan ilustrasi proses pencarian *frequent itemset* menggunakan algoritma Apriori. Contoh berikut menggunakan lima transaksi sederhana dan bukan merupakan hasil pengolahan dataset penelitian yang sebenarnya. Misalkan terdapat data transaksi seperti pada Tabel 3.3.

Tabel 3. 3 Contoh Transaksi untuk Perhitungan Manual Apriori

Transaksi	Produk yang Dibeli
T1	A, B, C
T2	A, B
T3	A, C
T4	B, C
T5	A, B, C

Pada contoh tersebut, jumlah transaksi adalah lima. Jika nilai minimum support ditetapkan sebesar 40%, jumlah minimum kemunculan suatu itemset dihitung sebagai berikut:

$$Minimum\ Support\ Count = 0{,}40 \times 5 = 2$$

Artinya, suatu itemset dinyatakan memenuhi minimum *support* apabila muncul sekurang-kurangnya dalam dua transaksi.

Langkah pertama adalah menghitung kemunculan setiap produk tunggal. Produk A muncul pada transaksi T1, T2, T3, dan T5 sehingga memiliki *support count* sebanyak empat. Produk B muncul pada T1, T2, T4, dan T5, sedangkan produk C muncul pada T1, T3, T4, dan T5. Ketiganya memiliki *suppo*rt sebesar 80%.

Selanjutnya, dihitung kemunculan kombinasi dua produk. Kombinasi AB muncul pada T1, T2, dan T5 sehingga support count-nya adalah tiga. Kombinasi AC dan BC masing-masing muncul pada tiga transaksi. Perhitungan support dilakukan menggunakan rumus:

$$Support(X) = Support\,\frac{Count(X)}{N} \times 100\%$$

Sebagai contoh, support kombinasi AB adalah:

$$Support(AB) = \frac{3}{5} \times 100\% = 60\%$$

Karena nilai support kombinasi AB sebesar 60% lebih tinggi daripada minimum support sebesar 40%, kombinasi tersebut termasuk *frequent itemset*. Prinsip yang sama digunakan untuk memeriksa kombinasi produk lainnya. Pada tahap berikutnya, kombinasi tiga produk ABC memiliki *support count* dua atau support sebesar 40%, sehingga masih memenuhi minimum support yang ditetapkan.

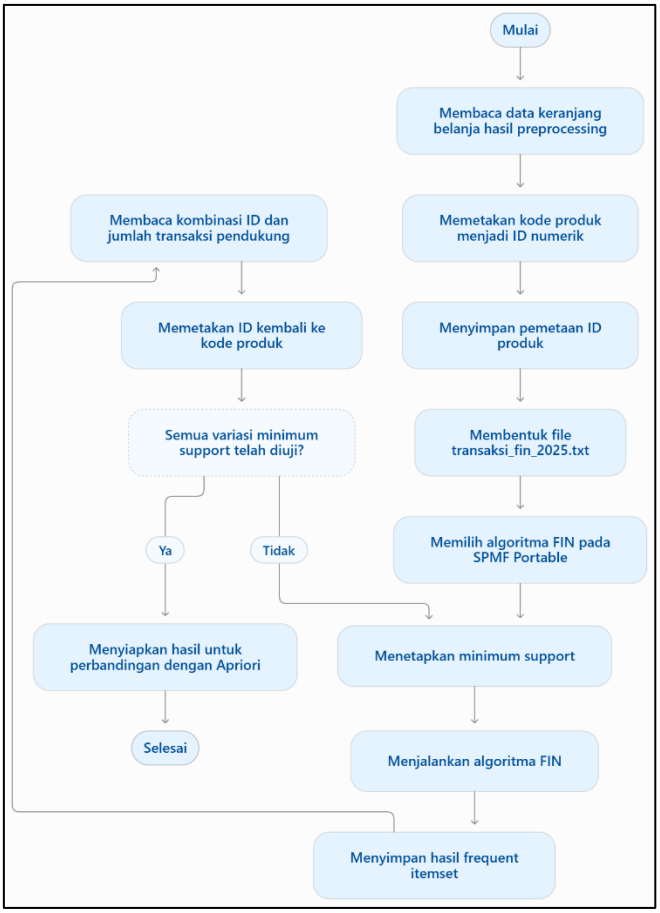
Perhitungan tersebut menggambarkan prinsip Apriori dalam menemukan kombinasi produk yang memenuhi batas minimum support secara bertahap. Pada penelitian sebenarnya,

proses pencarian dilakukan menggunakan pustaka `MLxtend` terhadap dataset transaksi swalayan dengan variasi minimum support 0,05%, 0,10%, dan 0,20%.

3.2.5 Implementasi Algoritma FIN

Implementasi algoritma FIN pada penelitian ini dilakukan menggunakan perangkat lunak SPMF Portable untuk menemukan *frequent itemset* pada data transaksi swalayan. Algoritma FIN diterapkan pada data transaksi yang sama dengan algoritma Apriori, yaitu data penjualan selama Januari sampai dengan Desember 2025 yang telah melalui tahap *preprocessing*. Penerapan kedua algoritma pada sumber data yang sama bertujuan agar hasil pencarian pola pembelian dapat dibandingkan secara konsisten.

Tahap implementasi FIN diawali dengan menyesuaikan format data keranjang belanja agar dapat diproses oleh algoritma. Setiap kode produk dipetakan menjadi ID numerik yang unik, kemudian pemetaan tersebut disimpan agar hasil pencarian dapat ditelusuri kembali ke kode produk aslinya. Selanjutnya, setiap transaksi dituliskan dalam berkas teks `transaksi_fin_2025.txt`, dengan setiap baris merepresentasikan satu transaksi yang berisi kumpulan ID produk.



Gambar 3. 3 Flowchart Implementasi Algoritma FIN

Berdasarkan Gambar 3.3, data transaksi yang telah melalui tahap *preprocessing* terlebih dahulu dipetakan ke dalam ID numerik dan disimpan dalam format masukan yang sesuai dengan kebutuhan SPMF Portable. Setelah berkas masukan tersedia, algoritma FIN dijalankan menggunakan tiga variasi *minimum support*. Penggunaan variasi tersebut disesuaikan dengan pengujian algoritma Apriori agar hasil pencarian kedua algoritma dapat dibandingkan pada batas minimum yang sama.

Hasil pencarian FIN disimpan dalam berkas keluaran yang memuat kombinasi ID produk dan jumlah transaksi pendukung. Informasi jumlah transaksi pendukung digunakan untuk mengetahui banyaknya transaksi yang memuat suatu kombinasi produk. Selanjutnya, ID produk pada hasil keluaran dipetakan kembali menggunakan berkas pemetaan produk agar kombinasi yang ditemukan dapat diidentifikasi berdasarkan kode produk aslinya.

Hasil implementasi FIN selanjutnya digunakan dalam evaluasi dan perbandingan *frequent itemset* dengan hasil algoritma Apriori. Perbandingan dilakukan berdasarkan jumlah *itemset*, kesamaan kombinasi produk, dan kesesuaian jumlah transaksi pendukung pada setiap nilai *minimum support*. Hasil perbandingan tersebut digunakan untuk mengetahui kesesuaian pola yang dihasilkan kedua algoritma pada konfigurasi pengujian yang digunakan.

3.2.6 Perhitungan Manual FIN

Perhitungan manual pada bagian ini digunakan untuk memperlihatkan cara memeriksa nilai frekuensi kemunculan kombinasi produk yang dihasilkan oleh algoritma FIN. Contoh transaksi yang digunakan sama dengan Tabel 3.3 agar hasilnya dapat dibandingkan dengan ilustrasi perhitungan Apriori.

Berdasarkan lima transaksi tersebut, kombinasi AB muncul sebanyak tiga kali, yaitu pada transaksi T1, T2, dan T5. Dengan demikian, *support count* kombinasi AB adalah tiga dan nilai *support*-nya sebesar:

$$Support\ (AB) = \frac{3}{5} \times 100\% = 60\%$$

Kombinasi ABC muncul pada transaksi T1 dan T5 sehingga memiliki *support count* dua dan nilai *support* sebesar:

$$Support(ABC) = \frac{2}{5} \times 100\% = 40\%$$

Jika minimum *support* yang digunakan sebesar 40%, kedua kombinasi tersebut memenuhi kriteria *frequent itemset*. Nilai *support count* dari kombinasi produk yang sama

seharusnya konsisten ketika ditemukan oleh Apriori maupun FIN pada dataset dan batas minimum *support* yang sama.

Dalam implementasi penelitian, FIN dijalankan menggunakan SPMF Portable. Algoritma memproses data transaksi yang telah dikonversi menjadi ID numerik dan menghasilkan frequent itemset beserta jumlah transaksi pendukungnya. Perhitungan manual ini berfungsi sebagai ilustrasi pemeriksaan nilai frekuensi, sedangkan proses internal algoritma FIN dan hasil pengujiannya diperoleh melalui implementasi program.

3.2.7 Pembentukan Aturan Asosiasi

Pembentukan aturan asosiasi dilakukan untuk mengetahui hubungan antara produk yang muncul secara bersamaan dalam transaksi. Aturan asosiasi dibentuk dari *frequent itemset* yang memenuhi minimum *support*. Pada penelitian ini, pembentukan aturan menggunakan minimum *confidence* sebesar 10%, kemudian nilai *support*, *confidence*, dan *lift* digunakan untuk menganalisis kekuatan aturan yang dihasilkan.

Misalnya, dari contoh transaksi pada Tabel 3.3 diperoleh kombinasi AB dengan *support count* tiga. Aturan asosiasi yang dapat dibentuk adalah $A \rightarrow B$ dan $B \rightarrow A$. Perhitungan dilakukan menggunakan rumus berikut:

$$Support(A \rightarrow B) = \frac{Count(A \cup B)}{N}$$

$$Confidence(A \rightarrow B) = \frac{Count(A \cup B)}{Count(A)}$$

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support(B)}$$

Berdasarkan contoh tersebut, produk A muncul empat kali, produk B muncul empat kali, dan kombinasi AB muncul tiga kali. Oleh karena itu, *support* kombinasi AB adalah 60%, *confidence* aturan $A \rightarrow B$ adalah 75%, dan *lift*-nya sebesar 0,9375.

Nilai tersebut menunjukkan bahwa *confidence* aturan $A \rightarrow B$ mencapai 75%, tetapi nilai lift kurang dari satu. Dengan demikian, tingginya *confidence* saja tidak selalu menunjukkan hubungan positif antara kedua produk. Dalam penelitian ini, nilai *lift* turut diperhatikan untuk mengidentifikasi aturan dengan keterkaitan positif antarproduk.

Perhitungan aturan asosiasi pada dataset penelitian dilakukan secara terprogram berdasarkan hasil frequent itemset. Hasilnya disimpan untuk dianalisis berdasarkan *support*, *confidence*, dan *lift* serta digunakan dalam pemilihan kandidat paket bundling.

3.2.8 Perancangan Rekomendasi Paket Bundling

Perancangan rekomendasi paket bundling dilakukan dengan memanfaatkan aturan asosiasi yang diperoleh dari data transaksi swalayan. Aturan yang memenuhi minimum *support* dan minimum *confidence* selanjutnya dianalisis menggunakan nilai *lift* untuk mengetahui keterkaitan antarproduk. Kombinasi produk yang menunjukkan keterkaitan positif dapat dipertimbangkan sebagai kandidat paket bundling.

Sebagai ilustrasi, digunakan lima transaksi pada Tabel 3.3. Produk A muncul dalam empat transaksi, produk B muncul dalam empat transaksi, dan kedua produk muncul secara bersamaan dalam tiga transaksi. Dengan demikian, aturan asosiasi $A \rightarrow B$ memiliki nilai *support*, *confidence*, dan *lift* sebagai berikut:

a. Menghitung *support*

$$Support(A \rightarrow B) = \frac{3}{5} \times 100\% = 60\%$$

Nilai tersebut menunjukkan bahwa kombinasi produk A dan B muncul dalam 60% dari seluruh transaksi pada contoh data.

b. Menghitung *confindence*

$$Confidece(A \rightarrow B) = \frac{3}{4} \times 100\% = 75\%$$

Nilai *confidence* sebesar 75% menunjukkan bahwa 75% transaksi yang memuat produk A juga memuat produk B.

c. Menghitung *lift*

$$Lift(A \rightarrow B) = \frac{0{,}75}{0{,}80} = 0{,}9375$$

Nilai *lift* sebesar 0,9375 menunjukkan bahwa kemunculan produk B pada transaksi yang memuat A tidak lebih tinggi daripada tingkat kemunculan B secara keseluruhan. Oleh karena itu, meskipun aturan tersebut memiliki *confidence* sebesar 75%, aturan ini tidak menunjukkan keterkaitan positif berdasarkan nilai *lift*.

Berdasarkan ilustrasi tersebut, penentuan kandidat bundling tidak cukup hanya mempertimbangkan nilai *confidence*. Aturan asosiasi juga perlu memenuhi minimum *support* dan menunjukkan nilai *lift* lebih dari satu. Sebagai contoh, apabila suatu aturan memenuhi seluruh kriteria tersebut, kombinasi produk pada aturan dapat dimasukkan ke dalam daftar kandidat paket bundling.

Pada implementasi penelitian, hasil aturan asosiasi akan diseleksi berdasarkan parameter yang telah ditetapkan. Hasilnya disajikan dalam bentuk daftar kombinasi produk

beserta nilai *support*, *confidence*, dan *lift*. Rekomendasi yang dihasilkan merupakan kandidat berdasarkan pola pembelian historis dan belum membuktikan bahwa bundling akan meningkatkan penjualan atau keuntungan swalayan.

3.2.9 Perancangan Pengujian dan Evaluasi

Pengujian dilakukan untuk membandingkan algoritma Apriori dan FIN dalam menemukan *frequent itemset* pada dataset transaksi swalayan. Kedua algoritma menggunakan data hasil preprocessing yang sama dengan tiga variasi minimum support, yaitu 0,05%, 0,10%, dan 0,20%.

Evaluasi dilakukan berdasarkan jumlah *frequent itemset*, kesesuaian kombinasi *itemset*, kesesuaian *support count*, dan waktu eksekusi. Perhitungan manual berikut digunakan untuk menjelaskan cara mengevaluasi kesesuaian hasil kedua algoritma.

a. Perhitungan minimum *support count*

Minimum *support count* digunakan untuk mengetahui jumlah minimum transaksi yang harus memuat suatu itemset agar itemset tersebut memenuhi nilai minimum *support*.

Rumus yang digunakan adalah:

$$Minimum\ Support\ Count = [s \times N]$$

Keterangan:

- s : nilai minimum *support* dalam bentuk desimal.
- N: jumlah transaksi yang diproses.
- [ ]: pembulatan ke atas karena jumlah transaksi berupa bilangan bulat.

Dengan jumlah transaksi sebanyak 35.218, perhitungan untuk setiap nilai minimum support adalah sebagai berikut:

Tabel 3. 4 Perhitungan minimum support count

Minimum support	Perhitungan	Minimum support count
0,05%	$[0{,}0005 \times 35.218]$	18
0,10%	$[0{,}0010 \times 35.218]$	36
0,20%	$0{,}0020 \times 35.218]$	71

Dengan demikian, pada minimum support 0,05%, suatu *itemset* harus muncul sekurang-kurangnya dalam 18 transaksi untuk memenuhi ambang tersebut. Pada minimum *support* 0,10% dan 0,20%, ambang minimumnya masing-masing adalah 36 dan 71 transaksi.

b. Perhitungan support suatu *itemset*

Misalnya, suatu kombinasi produk ditemukan pada 100 transaksi. Nilai *support*-nya dihitung sebagai berikut:

$$Support(X) = \frac{100}{35.218} \times 100\%$$

$$Support(X) \approx 0{,}284\%$$

Karena *support* sebesar 0,284% lebih tinggi daripada ketiga nilai minimum *support* yang diuji, kombinasi tersebut memenuhi ambang *support* 0,05%, 0,10%, dan 0,20%. Contoh ini hanya menjelaskan mekanisme perhitungan, bukan jumlah kemunculan produk pada dataset sebenarnya.

c. Perbandingan hasil Apriori dan FIN

Jumlah *frequent itemset* yang dihasilkan oleh kedua algoritma dicatat untuk setiap nilai minimum *support.* Selanjutnya, kombinasi produk dibandingkan berdasarkan identitas itemset dan jumlah transaksi pendukungnya.

Contoh sederhana: jika Apriori dan FIN sama-sama menemukan *itemset* $\{A, B\}$ dengan *support count* 100, maka *itemset* dan jumlah transaksi pendukungnya sesuai. Namun, apabila jumlah itemset kedua algoritma sama tetapi kombinasi produknya berbeda, hasil tersebut tidak dapat langsung dinyatakan identik.

Secara manual, tingkat kesesuaian itemset dapat dijelaskan menggunakan rumus:

$$Kesesuain = \frac{|I_A \cap I_F|}{|I_A \cup I_F|} \times 100\%$$

Keterangan:

- I_A : himpunan itemset hasil Apriori.
- I_F : himpunan itemset hasil FIN.
- $\cap$: irisan itemset yang sama.
- $\cup$: gabungan seluruh itemset dari kedua algoritma.

Sebagai ilustrasi, apabila kedua algoritma masing-masing menghasilkan 10 itemset dan seluruh *itemset* tersebut sama, nilai kesesuaiannya adalah 100%. Perhitungan aktual dilakukan dengan membandingkan seluruh *itemset* pada masing-masing ambang minimum *support*.

d. Evaluasi waktu eksekusi

Waktu eksekusi digunakan untuk membandingkan durasi proses pencarian *frequent itemset* oleh Apriori dan FIN. Misalnya, apabila pada suatu pengujian Apriori membutuhkan 2 detik dan FIN membutuhkan 1 detik, selisih waktunya adalah:

$$\Delta t = 2 - 1 = 1\ detik$$

Persentase pengurangan waktu FIN terhadap Apriori pada ilustrasi tersebut adalah:

$$\frac{2-1}{2} \times 100\% = 50\%$$

Angka tersebut hanya contoh perhitungan. Evaluasi penelitian akan menggunakan waktu eksekusi yang benar-benar tercatat dari program. Pengukuran kedua algoritma perlu menggunakan batas proses yang sebanding, yaitu mencakup pencarian pola dan tidak mencakup pembacaan data, *preprocessing*, atau penyimpanan hasil apabila bagian-bagian tersebut memang dikecualikan dalam implementasi.

Berdasarkan pengujian tersebut, hasil Apriori dan FIN dianalisis untuk mengetahui kesesuaian *frequent itemset*, kesamaan *support count*, serta perbedaan waktu eksekusi pada setiap nilai minimum *support*. Hasil pengujian aktual dan interpretasinya disajikan pada bab selanjutnya.

DAFTAR PUSTAKA

[1] R. Wahyuningsih and A. Suharsono, “COMPARISON OF MARKET BASKET ANALYSIS METHOD USING APRIORI ALGORITHM, FREQUENT PATTERN GROWTH (FP-GROWTH) AND EQUIVALENCE CLASS TRANSFORMATION (ECLAT) (CASE STUDY: SUPERMARKET ‘X’ TRANSACTION DATA FOR 2021).”

[2] N. T. S. Saptadi, P. Chyan, and J. M. Leda, “Analysis of Supermarket Product Purchase Transactions With the Association Data Mining Method,” *Jurnal RESTI*, vol. 7, no. 3, pp. 618–627, Jun. 2023, doi: 10.29207/resti.v7i3.4844.

[3] I. F. Rahman and D. Riana, “Market Basket Analysis untuk Penjualan Retail: Perbandingan Akurasi Algoritma Apriori dan FP-Growth Berbasis CRISP-DM,” *Jurnal Algoritma*, vol. 22, no. 1, pp. 468–479, May 2025, doi: 10.33364/algoritma/v.22-1.2303.

[4] P. Kallay and T. Dan Mihoc, “Comparative Analysis of Frequent Pattern Mining Algorithms,” *Acta Universitatis Sapientiae, Informatica*, vol. 17, no. 1, Aug. 2025, doi: 10.1007/s44427-025-00008-1.

[5] R. Khajuria, A. Sharma, S. Sharma, A. Sharma, J. N. Baliya, and P. Singh, “Performance analysis of frequent pattern mining algorithm on different real-life dataset,” *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 29, no. 3, pp. 1355–1363, Mar. 2023, doi: 10.11591/ijeecs.v29.i3.pp1355-1363.

[6] Z. U. Rizqi, “Implementasi Association Rule-Market Basket Analysis dalam Menentukan Strategi Product Bundling pada Usaha Ritel,” *Performa: Media Ilmiah Teknik Industri*, vol. 21, no. 2, p. 113, Sep. 2022, doi: 10.20961/performa.21.2.30156.

[7] Septianingsih and A. Bayu Santoso, “Implementasi Association Rule Mining Menggunakan Algoritma Apriori Untuk Rekomendasi Cross-Selling Produk Ritel,” *Jurnal Algoritma*, vol. 23, no. 1, May 2026, doi: 10.33364/algoritma/v.23-1.3381.

[8] Y. Fang, R. Wang, M. Guo, and Y. Hou, “Product bundling for online supermarkets by frequent itemset mining and optimization approach,” in *Procedia Computer Science*, Elsevier B.V., 2022, pp. 4434–4441. doi: 10.1016/j.procs.2022.09.507.

[9] A. Buana and R. Vikaliana, “Implementation of Association Rule Market Basket Analysis to Increase Sales Through Product Bundling Strategy at the Fashion Online Store,” *Journal Ilmiah Manajemen dan Bisnis*, vol. 10, no. 2, pp. 171–185, 2024.

[10] N. A. Hibnastiar, A. F. Setiawan, and E. H. Susanto, “Penerapan Algoritma Apriori dalam Menentukan Rekomendasi Paket Produk,” *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 5, no. 1, pp. 321–331, Jan. 2025, doi: 10.57152/malcom.v5i1.1782.

[11] K. Salunkhe *et al.*, “Uncovering Hidden Patterns: An Exploration of Market Basket Analysis in Retails,” 2024. [Online]. Available: https://www.jisem-journal.com/

[12] N. T. S. Saptadi, P. Chyan, and J. M. Leda, “Analysis of Supermarket Product Purchase Transactions With the Association Data Mining Method,” *Jurnal RESTI*, vol. 7, no. 3, pp. 618–627, Jun. 2023, doi: 10.29207/resti.v7i3.4844.

[13] F. Bao, L. Mao, Y. Zhu, C. Xiao, and C. Xu, “An Improved Evaluation Methodology for Mining Association Rules,” *Axioms*, vol. 11, no. 1, Jan. 2022, doi: 10.3390/axioms11010017.

[14] T. Setiawan, “Implementasi Data Mining Menggunakan Algoritma Apriori Untuk Menemukan Frequent Itemset Penjualan Sneakers,” *Jurnal Accounting Information System (AIMS*, vol. 6, no. 2, pp. 107–118, 2023, doi: 10.32627.

[15] A. Rahmadsyah and N. Mayasari, “Grouping Goods With The Association Rule Method Using A Priori Algorithms In Modern Retail Stores.” [Online]. Available: http://ijstm.inarah.co.id

[16] N. Karimtabar and M. J. S. Fard, “FINDING FREQUENT ITEMS: NOVEL METHOD FOR IMPROVING APRIORI ALGORITHM,” *Computer Science*, vol. 23, no. 2, pp. 161–177, 2022, doi: 10.7494/csci.2022.23.2.3776.

[17] M. Vives-Mestres, R. S. Kenett, S. Thió-Henestrosa, and J. A. Martín-Fernández, “Measurement, selection, and visualization of association rules: A compositional data perspective: A Compositional Data perspective on Association Rules,” *Qual. Reliab. Eng. Int.*, vol. 38, no. 3, pp. 1327–1339, Apr. 2022, doi: 10.1002/qre.2910.